

1 Матричное дифференцирование

1. Пусть $g: \mathbf{R}^n \rightarrow \mathbf{R}^m$, $x \in \mathbf{R}^n$. Матрицей Якоби называется матрица

$$\frac{\partial g}{\partial x} = \begin{pmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \frac{\partial g_2}{\partial x_1} & \frac{\partial g_2}{\partial x_2} & \cdots & \frac{\partial g_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_1} & \frac{\partial g_m}{\partial x_2} & \cdots & \frac{\partial g_m}{\partial x_n} \end{pmatrix}.$$

В частности, если $m = 1$ (т.е. $g(x)$ — скалярная функция векторного аргумента x), то $\frac{\partial g}{\partial x}$ — градиент функции g .

Доказать, что

- 1) если $a \in \mathbf{R}^n$, $x \in \mathbf{R}^n$, то $\frac{\partial(a^\top x)}{\partial x} = a$;
- 2) если $A \in \mathbf{R}^{m \times n}$, $x \in \mathbf{R}^n$, то $\frac{\partial(Ax)}{\partial x} = A$;
- 3) если $A \in \mathbf{R}^{n \times n}$, $x \in \mathbf{R}^n$, то $\frac{\partial(x^\top Ax)}{\partial x} = (A + A^\top)x$; в частности, если $A^\top = A$, то $\frac{\partial(x^\top Ax)}{\partial x} = 2Ax$;
- 4) если $x \in \mathbf{R}^n$, то $\frac{\partial\|x\|^2}{\partial x} = 2x$;
- 5) если g — скалярная функция и под $g(x)$ понимается применение функции g к каждой компоненте вектора $x \in \mathbf{R}^n$, то

$$\frac{\partial g(x)}{\partial x} = \text{diag}(g'(x)),$$

где $\text{diag}(a)$ — диагональная матрица с диагональю a ;

- б) если $h: \mathbf{R}^n \rightarrow \mathbf{R}^m$, $g: \mathbf{R}^m \rightarrow \mathbf{R}^p$, $x \in \mathbf{R}^n$, то

$$\frac{\partial g(h(x))}{\partial x} = \frac{\partial g(h(x))}{\partial h} \frac{\partial h(x)}{\partial x}.$$

v1.

$$a^T x = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} (x_1, \dots, x_n) = a_1 x_1 + a_2 x_2 + \dots + a_n x_n.$$

$$\frac{\partial a^T x}{\partial x} = \left(\frac{\partial a^T x}{\partial x_1}, \dots, \frac{\partial a^T x}{\partial x_n} \right) = (a_1, \dots, a_n) = a$$

v2.

$$Ax = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ a_{21} & \dots & a_{2n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n \end{pmatrix}$$

$(Ax)_i$ — i -ая компонента Ax .

$$\frac{\partial Ax}{\partial x} = \begin{pmatrix} \frac{\partial (Ax)_1}{\partial x_1} & \dots & \frac{\partial (Ax)_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial (Ax)_m}{\partial x_1} & \dots & \frac{\partial (Ax)_m}{\partial x_n} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

v3.

$$x^T A = (x_1, \dots, x_n) \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{pmatrix} = \left(\sum_{i=1}^n x_i a_{i1}, \dots, \sum_{i=1}^n x_i a_{in} \right)$$

$$\Rightarrow x^T A x = \left(\sum_{i=1}^n x_i a_{i1}, \dots, \sum_{i=1}^n x_i a_{in} \right) \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad (2)$$

$$\textcircled{2} \quad x_1 \sum_{i=1}^n x_i a_{i1} + x_2 \sum_{i=1}^n x_i a_{i2} + \dots + x_n \sum_{i=1}^n x_i a_{in} = f(x)$$

Найдем производную по x_1 , пом. используем правило

$$\frac{\partial f(x)}{\partial x_1} = \sum_{i=1}^n x_i a_{i1} + a_{11} x_1 + a_{12} x_2 + a_{13} x_3 + \dots + a_{1n} x_n =$$

$$= 2a_{11} x_1 + (a_{12} + a_{21}) x_2 + (a_{13} + a_{31}) x_3 + \dots + (a_{1n} + a_{n1}) x_n =$$

как видно $\frac{\partial f(x)}{\partial x_1}$ равен первой строке матрицы $(A + A^T)x$.

~4.

$$\|x\| = \sqrt{x_1^2 + \dots + x_n^2}, \quad \|x\|^2 = x_1^2 + \dots + x_n^2.$$

$$\frac{\partial \|x\|^2}{\partial x} = (2x_1 \ 2x_2 \ \dots \ 2x_n) = 2x$$

~5.

$$g(x) = \begin{pmatrix} g(x_1) \\ g(x_2) \\ \vdots \\ g(x_n) \end{pmatrix} \quad \frac{\partial g(x)}{\partial x} = \begin{pmatrix} g'(x) & 0 & \dots & 0 \\ 0 & g'(x) & & 0 \\ \vdots & & \ddots & \\ 0 & & & g'(x) \end{pmatrix}$$

~6

$$\frac{\partial g(h(x))}{\partial x} = \sum_{i=1}^n \frac{\partial g(h(x))}{\partial h_i(x)} \cdot \frac{\partial h_i(x)}{\partial x} = \frac{\partial g(h(x))}{\partial h} \cdot \frac{\partial h(x)}{\partial x}$$

2. Пользуясь № 1, найдите градиент $\frac{\partial g(\beta)}{\partial \beta}$ и гессиан $\frac{\partial^2 g(\beta)}{\partial \beta^T \partial \beta}$ функции $g(\beta) = \|\mathbf{X}\beta - \mathbf{y}\|^2$. Выведите отсюда, что решение линейной задачи наименьших квадратов $\hat{\beta} = \operatorname{argmin} \|\mathbf{X}\beta - \mathbf{y}\|^2$ является решением нормальной системы линейных уравнений $\mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y}$.
3. Дана обучающая выборка

x	1	1	0	0	-1
y	4	4	0	2	6

2

- 1) изобразить точки;
- 2) методом наименьших квадратов построить модель вида $f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$; построить график этой функции;
- 3) построить модель того же вида методом ридж-регрессии с параметром регуляризации $\lambda = 1$; построить график этой функции.
Замечание: при ручных вычислениях по методу наименьших квадратов рекомендуется составить систему $\mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y}$ и решить ее. Регуляризованная система: $(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})\beta = \mathbf{X}^T \mathbf{y}$, где \mathbf{I} — единичная матрица.
4. Рассмотрим задачу восстановления регрессии, в которой \mathbf{y} распределен согласно нормальному закону $N(\mathbf{X}\beta, \sigma^2 \mathbf{I})$, а β имеет априорное распределение $N(0, \tau^2 \mathbf{I})$. Найти апостериорное распределение для β . Доказать, что β^{ridge} есть его математическое ожидание. Найти связь между параметром регуляризации λ и дисперсиями τ, σ^2 .

N2.

$$g(\beta) = \|X\beta - y\|^2; \quad \frac{\partial g(\beta)}{\partial \beta} = ? \quad \frac{\partial^2 g(\beta)}{\partial \beta^T \partial \beta} = ?$$

$$\frac{\partial g(\beta)}{\partial \beta} = 2X^T(X\beta - y) \quad - \text{убедимся в этом, возьмем}$$

$$X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ \vdots & \vdots & & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix} \quad \beta = (\beta_1, \beta_2, \dots, \beta_n)^T$$

$$y = y_1;$$

$$g(\beta) = \|X\beta - y\|^2 = \left((x_{11} \beta_1 + x_{12} \beta_2 + \dots + x_{1n} \beta_n) - y_1 \right)^2 =$$

$$= (x_{11} \beta_1 + x_{12} \beta_2 + \dots + x_{1n} \beta_n - y_1)^2 \Rightarrow$$

$$\frac{\partial g(\beta)}{\partial \beta_1} = 2(x_{11} \beta_1 + x_{12} \beta_2 + \dots + x_{1n} \beta_n - y_1) \cdot x_{11} =$$

$$= 2(X\beta - y)X^T = 2X^T(X\beta - y)(1) \quad \begin{pmatrix} x_{11} \\ x_{12} \\ \vdots \\ x_{1n} \end{pmatrix}$$


$$\frac{\partial^2 g(\beta)}{\partial \beta^T \partial \beta} = \begin{pmatrix} \frac{\partial^2 g(\beta)}{\partial \beta_1^2} & \dots & \frac{\partial^2 g(\beta)}{\partial \beta_1 \partial \beta_n} \\ \vdots & & \vdots \\ \frac{\partial^2 g(\beta)}{\partial \beta_n \partial \beta_1} & \dots & \frac{\partial^2 g(\beta)}{\partial \beta_n^2} \end{pmatrix} = \begin{pmatrix} x_{11}^2 & x_{11}x_{12} & \dots & x_{11}x_{1n} \\ x_{11}x_{12} & x_{12}^2 & \dots & x_{12}x_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n}x_{11} & x_{1n}x_{12} & \dots & x_{1n}^2 \end{pmatrix} =$$

$$= 2X^T X.$$

uz (1) $2X^T(X\beta - y) = 0 \Rightarrow \hat{\beta} = \arg \min \|X\beta - y\|^2$
 пош. упр-2 $\Rightarrow X^T X \beta = X^T y$ м.е. $(X\beta - y) \rightarrow 0 \Rightarrow 2X^T(X\beta - y)$

~3.

$$\begin{array}{c|cccc} X & 1 & 1 & 0 & 0 & -1 \\ \hline y & 1 & 4 & 0 & 2 & 6 \end{array}$$



$$f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

$$X = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & -1 & 1 \end{pmatrix} \quad y = \begin{pmatrix} 1 \\ 4 \\ 0 \\ 2 \\ 6 \end{pmatrix}$$

$$X^T X = \begin{pmatrix} 5 & 1 & 3 \\ 1 & 3 & 1 \\ 3 & 1 & 3 \end{pmatrix}, \quad X^T y = \begin{pmatrix} 13 \\ -1 \\ 11 \end{pmatrix}$$

$$X^T X \beta = X^T y \Rightarrow \beta = \begin{pmatrix} 1 \\ -\frac{1}{4} \\ 3 \end{pmatrix}$$

maior $f(x) = 1 - \frac{4}{9}x + \frac{13}{9}x^2$.

$f(-1) \approx 6$; $f(0) = 1$; $f(1) \approx 2.5$.

$\lambda = 1$

$$X^T X + \lambda I = \begin{pmatrix} 6 & 1 & 3 \\ 1 & 4 & 1 \\ 3 & 1 & 4 \end{pmatrix} \Rightarrow (X^T X + \lambda I)\beta = X^T y \Rightarrow \beta = \begin{pmatrix} 75/56 \\ -61/56 \\ 113/56 \end{pmatrix}$$

$g f(x) = \frac{75}{56} - \frac{61}{56}x + \frac{113}{56}x^2$

$g f(x) = g(-1) \approx 4.5$; $g(0) \approx 1.34$; $g(1) \approx 2.27$.

4.

$y \sim N(X\beta, \sigma^2 I)$, $\beta \sim N(0, \tau I)$ $(\beta | y) \sim ?$

$y = X\beta + \lambda I \Rightarrow (y | \beta) \sim N(\lambda I, X\tau I)$.

$p(\beta | y) = \frac{p(y | \beta) \cdot p(\beta)}{p(y)} \Rightarrow (\beta | y) \sim \frac{N(\lambda I, X\tau I) \cdot N(0, \tau I)}{N(X\beta, \sigma^2 I)}$

$= N(0, \tau, \sigma^2) N(0, \frac{X\tau^2 I}{\sigma^2})$